

AI 활용 ② — 전처리: 무엇을 남기고 무엇을 뺄까

기초지질데이터과학 · 2026학년도 2학기 5주차 · 2026. 9. 28. · 과제 1 (5점) · 제출 오늘 23:59, LMS · 짝과 토론하고 제출은 각자

통계 규칙은 '의심할 후보'를 보여 줄 뿐입니다. 무엇을 지울지는 질문과 자료 밖의 지식이 정합니다.

준비. LMS 자료실의 파일 세 개 — 과제1_시작노트북_5주차.ipynb , sandstone_density.csv , eq_catalog_korea_2006_2025.csv — 와 데이터 명세서 ① 지진 카탈로그, 보조 ①②. Colab에서 파일 → 노트북 업로드로 노트북을 열고, 왼쪽 창에 CSV 두 개를 끌어다 놓습니다. 모든 답은 노트북 안에 씁니다.

Part A · 사암 밀도 — 3σ와 MAD (15분)

같은 사암층에서 나흘 동안 시료 40개의 겉보기 밀도를 잴습니다. 기록 규칙은 g/cm³였습니다. 강의 94쪽·109–113쪽과 같은 상황입니다.

A-1	AI에게 평균·표준편차로 z > 3인 행을 고르는 코드를 받아 실행합니다. 몇 개가 걸렸나요?
A-2	중앙값과 MAD로 바꿉니다: 로버스트 $z = (x - \text{중앙값}) / (1.4826 \times \text{MAD})$, z > 3이면 후보. 몇 개가 걸렸나요?
A-3	걸린 값마다 고침 · 뺄(NaN) · 남김 중 하나로 정하고 근거를 씁니다. 그리고 3σ가 A-1에서 놓친 이유를 한 문장으로.

Part B · 지진 목록 — 질문이 먼저다 (45분)

질문 (주어짐) 2006–2025년 한반도에서 규모 5.0 이상 지진은 몇 번 있었고, b값은 얼마인가?
자료를 보기 전에 예상부터 적습니다. 여러분은 경주(2016, M5.8)와 포항(2017, M5.4)을 압니다. b값은 보통 0.8–1.2입니다(명세서 ① 5 번).

B-1	자료 보기. 출처·규모종류별 개수, 규모와 깊이의 히스토그램. 명세서 ① 3. 알려진 합정 다섯 가지 중 이 자료에 있는 것을 찾습니다.	10분
B-2	AI에게 맡겨 보기. "이상치와 중복을 제거하는 코드"를 받아 고치지 말고 실행 → report() 로 원자료와 비교 → 지워진 행 중 규모가 큰 5개를 봅니다. 지워도 되는 행인가요? Part A의 MAD를 규모 에 적용해도 봅니다.	15분
B-3	내 정제. 결정표를 채우며 한 단계씩 — 필수: 출처 혼합, 완전히 같은 행, 발파, 큰 지진 / 선택: 시기별 Mc, 깊이 10.0 고정값. 단계마다 행 수를 출력합니다.	20분
B-4	비교와 결론. 원자료 · AI 정제 · 내 정제 세 줄을 나란히 놓고 보조 ②의 틀로 결론 세 문장. 그리고 MAD가 사암에서는 답이었는데 규모에는 왜 답이 아닌가.	B-5와 함께 10분 + 집에서
B-5	질문이 바뀌면? 질문이 "깊이 분포가 지역마다 다른가?"라면 B-3 결정표에서 무엇이 달라지나요? 한 가지 이상.	

근거는 AI 밖에서 — 쓸 수 있는 기준 다섯 가지

기준	예
기록 규칙 · 비교	단위 규칙(g/cm³), 결측 표기(-999), 현장 메모("풍화 심함")
물리적 범위	사암 겉보기 밀도는 대략 2.0–2.6 g/cm³ — 석영(2.65)·방해석(2.71)보다 클 수 없다
알려진 사실	경주 2016 M5.8은 실제로 일어났다 — 정제 뒤 목록에서 사라졌다면 틀린 것은 과정이다
자료의 모양	발생 시각대, 깊이 분포의 봉우리, 한 지점에 몰린 진앙, 단계마다의 행 수 변화
출처	누가, 어떤 규모 척도와 시간대로 기록했나 (ML · mb · Mw, KST · UTC)

채점 (5점)

항목	배점	인정 기준
코드 작동	2	Part A — 3σ와 MAD 결과가 둘 다 출력되어 있다 (1) · Part B — report() 세 줄(원자료 · AI 정제 · 내 정제)이 출력되어 있다 (1)
해석	2	원리 (1): 3σ가 놓친 이유, 또는 규모에 통계 규칙이 맞지 않는 이유를 강의 개념으로 설명했다 · 판단 (1): 결정 표 필수 네 항목의 근거가 AI 밖의 기준으로 적혀 있고, B-5에서 달라지는 결정을 하나 이상 짚었다
기록지	1	2건 이상(A-1 · B-2 포함), 5칸을 모두 채웠고 ④ 검증 칸에 AI 밖의 기준이 있다

④ 검증 칸이 모두 비어 있으면 해석은 0점입니다. "AI에게 다시 물어봤다", "다른 AI로 확인했다"는 검증으로 인정하지 않습니다. 정답이 하나인 과제가 아닙니다 — 같은 행을 두고 다른 결정을 해도 근거가 서면 인정합니다.

AI 활용 기록지 — 노트북 맨 아래 표

① 도구·모델	② 프롬프트 원문	③ AI 산출물	④ 검증 — 무엇을 보고 확인했나	⑤ 수정 — 무엇을 왜 바꿨나
Gemini (9/14)	"심도 열의 ft 값을 m로 바꾸는 코드"	셀 [3], 변환 코드	바꾼 행 중 세 개를 손으로 계산해 대조 (100 ft = 30.48 m). 변환 뒤 최대 심도가 시추공 깊이 150 m를 넘지 않는지 확인	없음 — 손계산과 일치

형식을 보여 주려고 2주차 사례 B로 만든 예입니다. 오늘 기록은 오늘 한 일로 씁니다.

④칸 예시 — 지난주 토론 결과지에서 뽑았습니다.

- "몇 개를 뽑아 직접 계산해 보고, 정제 전과 비교한다." — 자료가 많아도 할 수 있는 검증
- "규모 1-2 지진이 1년에 몇백 회라면 20년이면 몇천 회 — 결과가 이보다 크게 벗어나면 의심한다." — 예상값과 대조
- "결과가 원자료의 최댓값·최솟값을 벗어나거나, 그 심도에서 나올 수 없는 암석이 나오면 검토한다." — 물리적 범위

막히면

- 발생시각을 날짜로 바꾸다 오류가 나면 — 오류 메시지를 AI에게 넘기기 전에, 출처별로 발생시각이 어떻게 적혀 있는지 먼저 보세요. 오류를 없애 주는 옵션이 답을 조용히 틀리게 만들 수 있습니다.
- 중복을 지웠는데 0개라면 — 정말 0개가 맞는지, 어느 열 때문에 같은 행으로 잡히지 않았는지 보세요.
- b값이 그럴듯하게 나왔다면 — 무엇이 지워졌는지부터 보세요. 숫자 하나가 그럴듯하다고 과정이 맞은 것은 아닙니다.

자료 설명

sandstone_density.csv · 40행 시료번호 · 채취일 · 기재자 · 밀도(기록 규칙 g/cm³) · 비교	eq_catalog_korea_2006_2025.csv 번호 · 발생시각 · 규모 · 규모종류 · 깊이(km) · 위도 · 경도 · 위치 · 출처 — 명세서 ①의 '최대 진도' 열은 이 자료에 없습니다.
--	--

두 파일은 **교육용 합성 자료**입니다. 기상청·USGS 목록의 형식을 본떠 만들었고, 명세서 ①의 '알려진 함정'을 일부러 심었습니다. 큰 지진 몇 개(경주 2016, 포항 2017, 태안 해역 2014 등)는 실제 사건의 날짜와 규모를 따랐지만 시각·위치는 근사값입니다. **포트폴리오에는 실제 자료를 씁니다** — 오늘 쓴 명세서 형식이 그때 여러분이 채울 틀입니다.