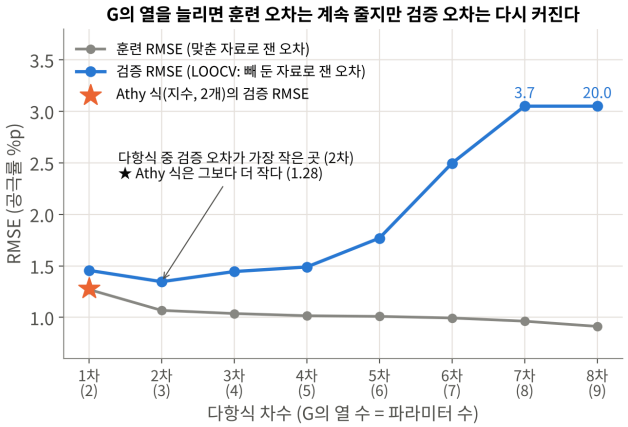
AI 활용 ④ — 최소자승에서 기계학습으로: 새 자료에서도 맞는가

기초지질데이터과학 · 9주차 · 2026. 11. 9. · 2교시 조 활동 → **참여 ③** (오늘 23:59, LMS — 노트북 하나, 각자 제출)

1교시 · 같은 문제, 두 가지 말

회귀 · 최소자승 (289–306쪽)	오늘 · 기계학습
d — 관측값	목표값 (target)
G의 열 — 기저함수 1, x, x^2, …	특성 (feature)
m — 모델 계수	파라미터 · 가중치
E = e^Te — 오차 제곱합	손실함수 (MSE = E/n)
$G^TG{\cdot}m = G^Td$ 풀기	학습 (또는 경사하강)
G의 열 수	모델 복잡도
—	**검증 오차** — 맞추는 데 쓰지 않은 자료로 잰 오차



G의 열을 늘리면 훈련 오차는 계속 줄지만 검증 오차는 다시 커진다 — 과적합.

손 계산 — 306쪽 네 점 (2, 1) (4, 4) (6, 3) (8, 4)의 직선 LOOCV

하나를 빼고 남은 세 점으로 직선을 맞춘 뒤, 뺀 점을 예측한다. 기울기 b = Σ(x − $\bar{x}$)(d − $\bar{d}$) / Σ(x − $\bar{x}$)², 절편 a = $\bar{d}$ − b·$\bar{x}$. **우리 분단은 접기 ___번.**

접기	뺀 둔 점	남은 세 점의 $\bar{x}$ · $\bar{d}$	b	a	예측 $\hat{d}$	오차 d − $\hat{d}$
1	(2, 1)					
2	(4, 4)					
3	(6, 3)					
4	(8, 4)					

모델 (G의 열 수)	0차 · 평균 (1)	1차 · 직선 (2)	2차 · 306쪽 (3)	3차 (4)
훈련 오차 E = e^Te	6.0	2.8	1.8	0
검증 RMSE (LOOCV)	1.63	_____	4.47	? — 왜?

AI의 모델 추천을 볼 때 다섯 질문

1. **자료 수 n과 파라미터 수 p는?** p가 n에 가까우면 보간이다.
2. **보고한 성능은 훈련 오차인가, 검증 오차인가?** 훈련 R^2는 열을 늘리면 늘 오른다.
3. **검증을 질문에 맞게 나눴나?** 더 깊은 곳 → 깊은 쪽을 남겨 검증, 새 시추공 → 시추공 단위로, 시간 → 앞뒤로.
4. **예측하려는 곳이 자료 범위 안인가?** 교차검증은 범위 안의 성능만 잰다.
5. **G의 열(기저함수 · 특성)에 물리 · 지질 근거가 있나?**

2교시 · AI 답변 검증 — 조별 (3–4명)

문제 = 조 번호를 3으로 나눈 나머지 (1 → 문제 1 · 2 → 문제 2 · 0 → 문제 3). 노트북 `참여3_시작노트북_9주차.ipynb`와 우리 조 CSV를 Colab에 올린다. 세 자료 모두 **교육용 합성 자료**.

시간	할 일
5–15분	**AI에게 묻기** — 아래 프롬프트를 **그대로** 보낸다(CSV 첨부 또는 붙여넣기). 후속 질문은 한 번 자유. 고른 모델 · 성능 숫자 · **그 숫자를 어떤 자료로 쟀는지**를 노트북에 기록.
15–40분	**검증** — 노트북의 표를 실행하고, AI가 고른 차수 · 층 · 변수로 바꿔 **같은 기준(LOOCV)**에서 다시 잰다. 다섯 질문을 하나씩.
40–55분	**반박문** — 아래 틀. AI에게 반박문을 보여 주고 다시 답하게 해 보는 것도 좋다(⑤).
55–72분	**발표** — 문제별 대표 1조 4분 + 다른 조 보충 1분.

문제 1 · 공극률–깊이 porosity_depth.csv

사암 시료 14개의 깊이(km, 0.24–2.96)와 공극률(%). 묻힐수록 압밀로 공극률은 깊이에 따라 지수적으로 준다고 알려져 있다 — Athy 식 $\phi = \phi_0 \cdot e^{-cz}$.

> 첨부한 사암 시료 14개의 깊이–공극률 자료(porosity_depth.csv)로 깊이 4.5 km의 공극률을 예측하고 싶어. 여러 모델을 비교해서 R^2가 가장 높은 모델을 고르고, 그 모델의 4.5 km 예측값과 파이썬 코드를 줘.

문제 2 · 코어 8개의 속도와 밀도 velocity_density.csv

퇴적암(사암 · 셰일 · 석회암) 코어 8개의 P파 속도(km/s)와 밀도(g/cm³). 퇴적암에서는 밀도가 속도의 약 1/4 제곱에 비례한다는 경험식이 알려져 있다 — Gardner 식 $\rho \approx a \cdot Vp^{0.25}$.

> 암석 코어 8개의 P파 속도와 밀도 자료(velocity_density.csv)가 있어. P파 속도로 밀도를 예측하는 딥러닝(신경망) 모델을 만들어 줘. 정확도가 높게 나오도록 은닉층을 충분히 깊게 하고, 정확도도 알려줘.

문제 3 · 시료 16개, 항목 12개 sandstone_features.csv

사암 시료 16개의 공극률(%)과 12개 항목: 깊이(km) · 점토 · 방해석 · 석영 · 장석(%, **네 광물의 합 = 100**) · 평균입경(mm) · 분급계수(클수록 분급 불량) · 감마선(API, 점토가 많을수록 크다) · 채취월 · 보관일수 · 시료무게(g) · 코어상자 번호. 사암의 공극률은 압밀(깊이), 점토의 공극 메움, 교결(방해석 등)로 줄어든다.

> 사암 시료 16개의 공극률과 측정 항목 12개 자료(sandstone_features.csv)가 있어. 정보를 하나도 버리지 않도록 모든 변수를 다 넣은 다중회귀로 공극률을 예측하는 모델을 만들고, 결정계수 R^2로 성능을 알려줘.

반박문 틀 (조가 함께 쓰고 각자 노트북에 붙여 제출)

1. **AI의 주장** — 핵심 문장 인용 한두 줄
2. **무엇이 틀렸거나 빠졌나** — 다섯 질문 중 몇 번에 걸리나
3. **근거** — 노트북의 수치(예: 검증 RMSE ○○ vs ○○) · 강의 쪽수 · 지질학적 이유
4. **대안** — 우리가 쓸 모델과 그 이유, 그리고 그 모델의 한계
5. (선택) **반박문을 보여 준 뒤 AI의 답** — 수긍했나? 고친 답에 새로 틀린 곳은?

AI가 처음부터 맞게 답했다면 같은 틀로 **검증 보고**를 쓴다: ②에 "다섯 질문 모두 통과", ③에 우리가 확인한 수치, ④에 AI가 말하지 않은 한계.

참여 ③ 인정: AI 답 인용 + 노트북 수치 근거 1개 이상 + 강의 · 지질 근거 1개 + 대안(또는 한계) + 기록지 1건 이상. 핵심은 AI가 틀렸는지가 아니라 **AI 밖의 근거로 확인했는가**입니다. · **막히면**: 노트북 0번 칸(도구)을 먼저 실행했는지, CSV 파일 이름이 그대로인지 확인.